

Biometryczne
wspomaganie interakcji człowiek-komputer
Biometria twarzy

Bartłomiej Stasiak

bartlomiej.stasiak@p.lodz.pl
basta@ics.p.lodz.pl

Instytut Informatyki
Politechnika Łódzka

2017

Plan wykładu

1 Biometria twarzy

- Wstęp
- Eigenfaces
- Inne metody
- Bazy zdjęć twarzy
- Rozpoznawanie twarzy – modele 3D
- Rozpoznawanie twarzy – analiza wielospektralna

Rozpoznawanie twarzy – wstęp

- Rozpoznawanie twarzy to jeden z najbardziej podstawowych sposobów identyfikacji osób wykorzystywany przez człowieka
- W systemach automatycznej identyfikacji i kontroli dostępu istotne są następujące elementy:
 - Wysoka akceptowalność i uniwersalność
 - Łatwość akwizycji, również bez wiedzy użytkownika
 - Duża zmienność wewnątrzklasowa (różne warunki akwizycji, oświetlenie, pozycja względem kamery, niejednorodne tło, zmienny wyraz twarzy, fryzura, zarost, okulary, i in.)
 - Umiarkowana unikalność i trwałość (zmiany spowodowane starzeniem, urazy, blizny)



Rozpoznawanie twarzy – wstęp

- Metody rozpoznawania twarzy można zasadniczo podzielić na:
 - Metody oparte na ekstrakcji cech – punktów charakterystycznych (oczy, brwi, nos, usta, podbródek), ich lokalizacji, kształtu i relacji przestrzennych (kąty, odległości)
 - Metody globalne, opisujące wygląd twarzy traktowanej jako obraz złożony z pewnej ilości obrazów składowych
 - Eigenfaces (PCA, ang. *Principal Component Analysis*)
 - Fisherfaces (LDA, ang. *Linear Discriminant Analysis*)
 - Tensorfaces (HOSVD, ang. *Higher-Order Singular Value Decomposition*)
 - Corefaces (shift-invariant PCA-correlation filter)
 - Metody oparte na odwzorowaniach LPP (ang. *Locality Preserving Projections* w przestrzeniach topologicznych)
 - Metoda EBGM (ang. *Elastic Bunch Graph Matching*)
 - Modelowanie 3D
 - ...

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Klasyczna metoda rozpoznawania twarzy oparta na dekompozycji twarzy za pomocą “twarzy wzorcowych/prototypowych”
 - M. Turk and A. Pentland (1991). “Eigenfaces for recognition”. Journal of Cognitive Neuroscience 3 (1): 71–86.



Rozpoznawanie twarzy – Eigenfaces (PCA)

- Niech \mathbf{x} będzie wektorem w N -wymiarowej przestrzeni unitarnej, a zbiór $\{\varphi_i : i = 0, 1, \dots, N - 1\}$ niech będzie pewną bazą tej przestrzeni
- Wektor \mathbf{x} możemy zatem przedstawić jako:

$$\mathbf{x} = \sum_{n=0}^{N-1} \varphi_n y(n) = F \mathbf{y} \quad (1)$$

gdzie kolumny macierzy F stanowią wektory bazowe:

$$F = [\varphi_0 \varphi_1 \dots \varphi_{N-1}]$$

zaś składowe wektora \mathbf{y} interpretujemy jako współrzędne wektora \mathbf{x} względem bazy $\{\varphi_i\}$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Aby obliczyć składowe $y(n)$ dla danego \mathbf{x} mnożymy (iloczyn skalarny) obie strony równania (1) kolejno przez wszystkie wektory bazowe φ_j , dla $j = 0, 1, \dots, N-1$

$$\langle \mathbf{x}, \varphi_j \rangle = \sum_{n=0}^{N-1} \langle \varphi_n, \varphi_j \rangle y(n)$$

- Otrzymujemy w ten sposób układ N równań liniowych z niewiadomymi $y(n)$:

$$A\mathbf{y} = \mathbf{a}$$

gdzie:

$$A = \begin{bmatrix} \langle \varphi_0, \varphi_0 \rangle & \cdots & \langle \varphi_{N-1}, \varphi_0 \rangle \\ \vdots & \ddots & \vdots \\ \langle \varphi_0, \varphi_{N-1} \rangle & \cdots & \langle \varphi_{N-1}, \varphi_{N-1} \rangle \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} \langle \mathbf{x}, \varphi_0 \rangle \\ \vdots \\ \langle \mathbf{x}, \varphi_{N-1} \rangle \end{bmatrix}$$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Z liniowej niezależności wektorów φ_i mamy, że $\det(A) \neq 0$, a zatem:

$$\mathbf{y} = A^{-1}\mathbf{a}$$

- Zakładając dodatkowo, że baza $\{\varphi_i\}$ jest ortogonalna, tj. że

$$\langle \varphi_k, \varphi_m \rangle = \begin{cases} 0 & , \text{ if } k \neq m \\ \|\varphi_k\|^2 & , \text{ if } k = m \end{cases}$$

otrzymujemy diagonalną macierz A :

$$A = \text{diag}(\|\varphi_0\|^2, \|\varphi_1\|^2, \dots, \|\varphi_{N-1}\|^2)$$

- Jeśli przyjmiemy bazę $\{\varphi_i\}$ *ortonormalną*, wówczas macierz A będzie macierzą jednostkową i oczywiście $A = A^{-1}$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Reasumując, dla ortonormalnej bazy $\{\varphi_i\}$ wektor \mathbf{y} obliczymy jako:

$$\mathbf{y} = A^{-1}\mathbf{a} = \mathbf{a} = \begin{bmatrix} \langle \mathbf{x}, \varphi_0 \rangle \\ \vdots \\ \langle \mathbf{x}, \varphi_{N-1} \rangle \end{bmatrix} = \begin{bmatrix} \varphi_0^T \\ \vdots \\ \varphi_{N-1}^T \end{bmatrix} \mathbf{x}$$

czyli $\mathbf{y} = F^T \mathbf{x}$

- Zauważmy, że w tym przypadku F jest macierzą ortogonalną $F^T = F^{-1}$ oraz, że współrzędne $y(n)$ w reprezentacji:

$$\mathbf{x} = \sum_{n=0}^{N-1} \varphi_n y(n)$$

obliczamy po prostu jako iloczyny skalarne wektora \mathbf{x} z odpowiednimi wektorami bazowymi: $y(n) = \langle \mathbf{x}, \varphi_n \rangle$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Baza ortonormalna $\{\varphi_i\}$ może być ustalona z góry
 - Przekształcenie Fouriera (ang. *Discrete Fourier Transform*, DFT)
 - Przekształcenie Hartley'a (ang. *Discrete Hartley Transform*, DHT)
 - Przekształcenie cosinusowe (ang. *Discrete Cosine Transform*, DCT)
 - ...
- Można również wyznaczyć wektory bazowe dla danego zbioru wektorów wejściowych (każdy zbiór danych wejściowych będzie miał wtedy “swoją” bazę $\{\varphi_i\}$)
 - W metodzie PCA wykorzystujemy w tym celu wektory własne macierzy kowariancji zbioru wejściowego

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Załóżmy, że zbiór wejściowy dany jest w postaci macierzy $X_{N \times M}$, w której każda kolumna \mathbf{x}_m reprezentuje cechy jednego spośród M obiektów
 - Jeśli obiektami wejściowymi są obrazy, możemy przyjąć, że odpowiadające im wektory \mathbf{x}_m powstają poprzez konkatencję wierszy lub kolumn
- Zakładamy, że dane wejściowe zostały wstępnie “wycentrowane”, tj. od każdej kolumny odjęto wektor średnich:

$$\forall m = 0, 1, \dots, M - 1 : \mathbf{x}_m := \mathbf{x}_m - \boldsymbol{\mu}$$

gdzie elementy wektora $\boldsymbol{\mu}$ obliczamy jako:

$$\mu(n) = \frac{1}{M} \sum_{m=0}^{M-1} \mathbf{x}_m(n)$$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Dla danych wejściowych \mathbf{x} obliczamy macierz kowariancji

$$\Sigma_{\mathbf{x}} = [\Sigma_{ij}] = E[(\mathbf{x} - E[\mathbf{x}])(\mathbf{x} - E[\mathbf{x}])^T], \text{ gdzie:}$$

$$\Sigma_{ij} = \text{cov}(x(i), x(j)) = E[(x(i) - E[x(i)])(x(j) - E[x(j)])]$$

dla $i, j = 0, 1, \dots, N - 1$, lub równoważnie:

$$\Sigma_{ij} = E[(x(i))(x(j))] - E[x(i)]E[x(j)]$$

lub prościej – uwzględniając, że odjęliśmy średnie:

$$\Sigma_{ij} = E[(x(i))(x(j))]$$

- W praktyce, macierz kowariancji może być estymowana na podstawie danych wejściowych (po odjęciu średnich):

$$\Sigma_{\mathbf{x}} = E[\mathbf{x}\mathbf{x}^T] \approx \frac{1}{M}\mathbf{X}\mathbf{X}^T = \frac{1}{M} \sum_{m=0}^{M-1} \mathbf{x}_m \mathbf{x}_m^T$$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Zauważmy, że Σ_x jest macierzą symetryczną ($\Sigma_x^T = \Sigma_x$), a zatem jej wektory własne są wzajemnie ortogonalne
 - Istotnie, dla dowolnych wektorów własnych φ_i , φ_j i związanych z nimi wartości własnych $\lambda_i \neq \lambda_j$, mamy:

$$\Sigma_x \varphi_i = \lambda_i \varphi_i \quad (2)$$

$$\Sigma_x \varphi_j = \lambda_j \varphi_j \quad (3)$$

Mnożąc (2) lewostronnie przez φ_j^T , a transpozycję (3) prawostronnie przez φ_i i odejmując stronami otrzymujemy:

$$0 = (\lambda_i - \lambda_j) \varphi_j^T \varphi_i$$

a zatem wektory φ_i , φ_j są ortogonalne
(dla $\lambda_i = \lambda_j$ można je również łatwo zortogonalizować)

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Zauważmy także, że Σ_x jest macierzą nieujemnie określoną, tj.

$$\mathbf{v}^T \Sigma_x \mathbf{v} \geq 0$$

dla dowolnego niezerowego wektora \mathbf{v}

- A zatem, dla dowolnego wektora własnego φ_i o znormalizowanej długości ($\varphi_i^T \varphi_i = 1$) mamy:

$$\Sigma_x \varphi_i = \lambda_i \varphi_i$$

skąd:

$$0 \leq \varphi_i^T \Sigma_x \varphi_i = \lambda_i$$

- Ponadto, jeśli Σ_x jest odwracalna, wówczas $\lambda_i \neq 0$ (wyznacznik macierzy kwadratowej jest równy iloczynowi jej wartości własnych)
- W takim wypadku mamy więc, że:

Wartości własne macierzy korelacji są dodatnie

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Rozważmy teraz macierz przekształcenia F złożoną z (kolumnowych) wektorów własnych $\varphi_0, \varphi_1, \dots, \varphi_{N-1}$ macierzy kowariancji Σ_x :

$$\mathbf{y} = F^T \mathbf{x}$$

- Po odjęciu średnich mamy $E[\mathbf{x}] = 0 \implies E[\mathbf{y}] = 0$, a więc macierz kowariancji Σ_y obliczymy jako:

$$\Sigma_y = E[\mathbf{y}\mathbf{y}^T] = E[F^T \mathbf{x}\mathbf{x}^T F] = F^T \Sigma_x F$$

- Z definicji macierzy F wynika zatem natychmiast, że Σ_y jest macierzą diagonalną:

$$\Sigma_y = \text{diag}(\lambda_0, \lambda_1, \dots, \lambda_{N-1})$$

- Podobnie, macierz korelacji dla Y będzie również diagonalna
- **A zatem przekształcenie F prowadzi do dekorelacji danych wejściowych**

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Zastępując macierz przekształcenia F macierzą złożoną z K wektorów bazowych ($K < N$):

$$\hat{F}_{N \times K} = [\varphi_0, \varphi_1, \dots, \varphi_{K-1}]$$

otrzymujemy pewną aproksymację wektora \mathbf{x} :

$$\hat{\mathbf{x}} = \sum_{i=0}^{K-1} y(i) \varphi_i$$

stanowiącą jego rzut na podprzestrzeń wyznaczoną przez pierwsze K wektorów własnych macierzy kowariancji Σ_x

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Istotną kwestią jest taki wybór wektorów własnych, który zminimalizuje oczekiwany błąd aproksymacji (MSE, *Mean Square Error*):

$$E \left[||\mathbf{x} - \hat{\mathbf{x}}||^2 \right] = E \left[\left\| \sum_{i=K}^{N-1} y(i) \boldsymbol{\varphi}_i \right\|^2 \right]$$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Pamiętając, że:

$$\|\mathbf{v}\|^2 = \mathbf{v}^T \mathbf{v}$$

oraz korzystając z ortogonalności wektorów φ_i łatwo pokazać, że:

$$E[\|\mathbf{x} - \hat{\mathbf{x}}\|^2] = \sum_{i=K}^{N-1} E[y^2(i)]$$

- Ponadto uwzględniając, że $\mathbf{y} = F^T \mathbf{x}$, mamy:

$$\begin{aligned} E[\|\mathbf{x} - \hat{\mathbf{x}}\|^2] &= \sum_{i=K}^{N-1} E[(\varphi_i^T \mathbf{x})(\varphi_i^T \mathbf{x})] = \\ &= \sum_{i=K}^{N-1} E[(\varphi_i^T \mathbf{x})(\mathbf{x}^T \varphi_i)] = \sum_{i=K}^{N-1} (\varphi_i^T E[\mathbf{x} \mathbf{x}^T] \varphi_i) \end{aligned}$$

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Ponieważ po odjęciu średnich od wektora \mathbf{x} mamy:

$$E[\mathbf{x}\mathbf{x}^T] = \Sigma_{\mathbf{x}}$$

możemy więc skorzystać z definicji wektora własnego, otrzymując ostatecznie:

$$E[\|\mathbf{x} - \hat{\mathbf{x}}\|^2] = \sum_{i=K}^{N-1} (\varphi_i^T \lambda_i \varphi_i) = \sum_{i=K}^{N-1} \lambda_i$$

- A zatem wybierając K wektorów własnych macierzy kowariancji związanych z K **największymi wartościami własnymi** uzyskujemy minimalizację błędu aproksymacji, który jest wówczas równy sumie $N - K$ najmniejszych wartości własnych

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Bezpośrednie wykorzystanie macierzy kowariancji obrazów wejściowych jest zwykle zbyt złożone obliczeniowo
 - Przykładowo, obraz 100×100 pikseli reprezentujemy jako wektor $100 \cdot 100 = 10,000$ -elementowy
 - Macierz kowariancji Σ_x będzie mieć zatem wymiary $10,000 \times 10,000$ (100,000,000 elementów!)
 - Jednak rząd macierzy Σ_x jest ograniczony liczbą obrazów (dla N obrazów tylko $N - 1$ wektorów własnych będzie mieć niezerowe wartości własne)
- Jeśli liczba obrazów (treningowych) jest mniejsza w stosunku do ich wymiarów (ilości pikseli) można zastosować mniej złożoną obliczeniowo metodę obliczania PCA

Rozpoznawanie twarzy – Eigenfaces (PCA)

- Po odjęciu średnich od macierzy wektorów wejściowych obliczamy: $\Sigma_x \approx XX^T$
- Z definicji wektorów własnych:

$$\lambda_i \varphi_i = \Sigma_x \varphi_i = XX^T \varphi_i$$

- Jednak macierz XX^T ma duże wymiary – obliczamy więc wektory własne dla macierzy $X^T X$:

$$X^T X \psi_i = \lambda_i \psi_i$$

- Mnożąc obie strony przez X mamy:

$$XX^T X \psi_i = \lambda_i X \psi_i$$

co oznacza, że jeśli ψ_i jest wektorem własnym macierzy $X^T X$, to $\varphi_i = X \psi_i$ jest wektorem własnym macierzy Σ_x

Rozpoznawanie twarzy – Fisherfaces (LDA)

- Analiza składowych głównych (PCA) pozwala na reprezentację danych optymalną w sensie współczynnika kompresji, ale nie uwzględnia podziału na klasy
- Wykorzystanie informacji o klasach zapewnia liniowa analiza dyskryminacyjna (ang. *linear discriminant analysis* / *Fisher's linear discriminant*, LDA/FLD)
 - Rozważmy dwie klasy obiektów, reprezentowanych przez wektory cech \mathbf{x} i założmy, że ich wektory średnich dane są jako μ_0 i μ_1 , a macierze kowariancji jako Σ_0 i Σ_1 , odpowiednio
 - Poszukujemy takiej kombinacji liniowej cech $\mathbf{w}^T \mathbf{x}$, która zmaksymalizuje separację pomiędzy klasami

Rozpoznawanie twarzy – Fisherfaces (LDA)

- Zauważmy, że wartości średnie kombinacji liniowej $\mathbf{w}\mathbf{x}$ będą równe $\mathbf{w}\boldsymbol{\mu}_0$ i $\mathbf{w}\boldsymbol{\mu}_1$ dla obu klas, odpowiednio
- Podobnie, wariancje w obu klasach obliczymy jako: $\mathbf{w}^T \boldsymbol{\Sigma}_0 \mathbf{w}$ i $\mathbf{w}^T \boldsymbol{\Sigma}_1 \mathbf{w}$, odpowiednio
- Zatem *separację* (FLD) pomiędzy rozkładami cech w obu klasach definiujemy jako:

$$S = \frac{\sigma_{mk}^2}{\sigma_{wk}^2} = \frac{(\mathbf{w}^T \boldsymbol{\mu}_1 - \mathbf{w}^T \boldsymbol{\mu}_0)^2}{\mathbf{w}^T \boldsymbol{\Sigma}_1 \mathbf{w} + \mathbf{w}^T \boldsymbol{\Sigma}_0 \mathbf{w}} = \frac{\left(\mathbf{w}^T (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)\right)^2}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}}$$

- Maksymalną separację pomiędzy klasami uzyskujemy dla wektora \mathbf{w} danego jako:

$$(\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1)^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_0$$

Rozpoznawanie twarzy – Fisherfaces (LDA)

- W ogólnym przypadku c klas definiujemy macierz rozproszenia międzyklasowego (ang. *between-class scatter matrix*):

$$S_B = \sum_{i=0}^{c-1} N_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T$$

... oraz macierz rozproszenia wewnątrzklasowego (ang. *within-class scatter matrix*):

$$S_W = \sum_{i=0}^{c-1} \sum_{\mathbf{x}_k \in X_i} (\mathbf{x}_k - \boldsymbol{\mu}_i)(\mathbf{x}_k - \boldsymbol{\mu}_i)^T$$

gdzie c jest liczbą klas, a N_i jest liczbą elementów w klasie X_i .

Rozpoznawanie twarzy – Fisherfaces (LDA)

- Optymalne wektory bazowe otrzymujemy poprzez maksymalizację wyrażenia:

$$W_{\text{opt}} = \operatorname{argmax}_W \frac{|W^T S_B W|}{|W^T S_W W|} = [\mathbf{w}_0, \dots, \mathbf{w}_K]$$

gdzie $\{\mathbf{w}_i\}$ to zbiór uogólnionych wektorów własnych, odpowiadający uogólnionym wartościom własnym $\{\lambda_i\}$:


$$S_B \mathbf{w}_i = \lambda_i S_W \mathbf{w}_i$$

- Z uwagi na wysoki wymiar przestrzeni wejściowej (w stosunku do ilości twarzy) w metodzie *Fisherfaces* dokonuje się najpierw redukcji wymiaru za pomocą PCA:


$$W_{FLD} = \operatorname{argmax}_W \frac{|W^T W_{\text{PCA}}^T S_B W_{\text{PCA}} W|}{|W^T W_{\text{PCA}}^T S_W W_{\text{PCA}} W|}$$

Rozpoznawanie twarzy

- Metoda EBGM (ang. *Elastic Bunch Graph Matching*) opiera się na modelowaniu twarzy za pomocą grafu łączącego punkty charakterystyczne (kąciaki oczu, nos, podbródek)



- Do generowania cech wykorzystuje się rodzinę falek Gabora o różnej częstotliwości i orientacji



Rozpoznawanie twarzy

- Metoda AAM (ang. *Active Appearance Models*)



- Tensorfaces
 - Zbiór technik rozpoznawania twarzy w oparciu o metody algebry wieloliniowej
 - Zbiór treningowy zróżnicowany pod względem tożsamości użytkowników, a także warunków oświetleniowych, póz, etc. modeluje się za pomocą tensorów/macierzy o wymiarach $N_{pixel} \times (N_{user} \times N_{light} \times N_{pose})$
 - Przekształcenie HOSVD, (ang. *Higher-Order Singular Value Decomposition*) pozwala na dekompozycję k -wymiarowych tensorów na sumę ważoną (zewnątrznych) iloczynów k niezależnych wektorów

Rozpoznawanie twarzy – bazy testowe

- Face Recognition Grand Challenge (FRGC)
 - Konkurs organizowany przez NIST
 - Zbiór treningowy
 - *Generic training set* 12,776 zdjęć (222 osób) wykonanych w kontrolowanych i niekontrolowanych warunkach oświetleniowych
 - Zbiór testowy
 - *Target set (gallery set)* 16,028 zdjęć (466 osób) wykonanych w kontrolowanych warunkach oświetleniowych
 - *Probe set* 8,014 zdjęć (466 osób) wykonanych w niekontrolowanych warunkach oświetleniowych



Rozpoznawanie twarzy – bazy testowe

- Pose Illumination Expression (PIE)
 - Baza zdjęć opracowana przez CMU
 - 41,368 zdjęć twarzy (68 osób)
 - 13 różnych póz, 43 różnych warunków oświetleniowych,
 - 4 typy wyrazów twarzy (neutralny, uśmiech, mruganie, rozmowa)



Rozpoznawanie twarzy – bazy testowe

- Baza YALE
 - 165 obrazów (gif) w odcieniach szarości
 - 15 osób
 - 11 zdjęć jednej osoby
 - światło z przodu/z lewej/z prawej
 - z okularami i bez
 - wyraz twarzy
neutralny/smutny/wesoły/śpiący/zdziwiony/mruganie



Rozpoznawanie twarzy – modele 3D

- Motywacja: większa niezależność od warunków oświetleniowych, w stosunku do metod “fotometrycznych” (2D)
- Akwizycja:
 - Wykorzystanie oświetlenia strukturalnego (*active structured lighting*)
 - Analiza obrazów stereoskopowych
 - Akwizycja pasywna
 - Akwizycja wspomagana (projekcja wzorca-tekstury na skanowaną powierzchnię)
 - Wynik akwizycji otrzymujemy jako zbiór punktów w przestrzeni 3D, ew. wraz ze zbiorem krawędzi, tworzącym siatkę (ang. *mesh*)

Rozpoznawanie twarzy – modele 3D

- Przetwarzanie danych:
 - Uzupełnianie brakujących punktów
 - Wygładzanie (redukcja szumu)
 - Ekstrakcja cech lokalnych
 - Obliczenie lokalnych deskryptorów kształtu pozwala na wykrycie cech twarzy przydatnych w rejestracji obrazów i porównywaniu ze wzorcem
 - Przykładowo, analiza krzywizny powierzchni twarzy i jej modelowanie (modele 2 lub 3 stopnia) pozwala na lokalizację maksimów (np. czubek nosa), minimów (kąciaki oczu), czy punktów siodłowych
 - Inną metodę stanowi analiza normalnych $n(x, y)$ do płaszczyzny $f(x, y)$, stycznej do powierzchni twarzy w danym punkcie:

$$f(x, y) = z = ax + by + c$$

$$n(x, y) = \frac{[-a, -b, 1]}{\sqrt{(1 + a^2 + b^2)}}$$

Rozpoznawanie twarzy – modele 3D

- Metody reprezentacji i rozpoznawania:
 - Oparte na całościowej – *kompletnej* reprezentacji 3D twarzy
 - Możliwość (przybliżonej) rekonstrukcji twarzy na podstawie reprezentacji
 - Oparte na reprezentacjach *niekompletnych*
 - Większa odporność na zniekształcenia, okluzje, etc.

Rozpoznawanie twarzy – modele 3D

- Do grupy metod całościowych (rekonstrukcja przybliżona) należą metody oparte na PCA/LDA
 - Podejście analogiczne jak w przypadku obrazów 2D (zamiast odcienia szarości – głębokość/współrzędna z)
 - Konieczność normalizacji/rejestracji obrazu (tak samo jak w przypadku 2D)
 - Wrażliwość na zmiany wyrazu twarzy (tak samo jak w przypadku 2D)
 - Niewrażliwość na zmiany oświetlenia (w większości przypadków)
 - Składowa głębokości (z) ma bardziej niskoczęstotliwościowy charakter w por. do intensywności \Rightarrow możliwość użycia mniejszej liczby głównych składowych (*principal components*)

Rozpoznawanie twarzy – modele 3D

- Metoda *Iterative Closest Point* (ICP)
 - Zakłada się, że kształt twarzy po akwizycji (zwykle zbiór punktów w przestrzeni 3D) jest “podzbiorem” kształtu modelowego (wzorca)
 - Poszukuje się odpowiedniego przekształcenia “sztywnego” (obroty, translacje) dopasowującego kształt twarzy do wzorca
 - Etapem wstępnym dopasowania jest dopasowanie środków ciężkości reprezentacji twarzy i wzorca
 - Następnie wykonuje się iteracyjnie kroki:
 - 1 Dopasowanie poszczególnych punktów metodą najbliższego sąsiada
 - 2 Obliczenie współczynników optymalnego przekształcenia dla dopasowania z p. 1
 - W celu redukcji ryzyka utknięcia w minimum lokalnym algorytm ICP wykonuje się zwykle wielokrotnie

Rozpoznawanie twarzy – modele 3D

- Modele deformacji (*deformation models*)
 - Podstawę analizy stanowi neutralny wyraz twarzy (“*neutral mesh*”)
 - Określa się lokalizację *punktów kontrolnych*, zależnych od wyrazu twarzy
 - Punkty kontrolne są dopasowywane pomiędzy porównywanymi obrazami i wykorzystywane do deformacji “neutralnej” siatki twarzy wzorcowych
- Niezależnie od metody rozpoznawania twarzy, w celu redukcji obliczeń można zastosować indeksowanie (wstępną selekcję – odrzucanie mało prawdopodobnych modeli)
 - Sferyczna reprezentacja twarzy i porównanie histogramów ilości punktów w funkcji odległości od ustalonego punktu twarzy (np. czubka nosa)

Rozpoznawanie twarzy – analiza wielospektralna

- Jednym z podstawowych problemów rozpoznawania twarzy jest wrażliwość na warunki oświetleniowe
 - Model generacji obrazu:

$$f(x, y) = i(x, y) \cdot r(x, y)$$

gdzie:

$r \in (0, 1)$ – współczynnik odbicia (ang. *reflectance*)

$i \in (0, \infty)$ – oświetlenie (ang. *illumination*)

- Aby zminimalizować wpływ czynnika i można wykorzystać metody analizy wielospektralnej (ang. *multispectral analysis*), tj. obrazowanie w różnych zakresach długości fal elektromagnetycznych

Rozpoznawanie twarzy – analiza wielospektralna

- Przykład twarzy w różnych zakresach promieniowania EM



- (a) pasmo widzialne: $0.4\text{--}0.7\mu\text{m}$
- (b) bliska podczerwień (*near infrared*, NIR / *shortwave infrared*, SWIR): $0.9\text{--}1.7\mu\text{m}$
- (c) średnia podczerwień (*midwave infrared*, MWIR): $3.0\text{--}5.0\mu\text{m}$
- (d) (*longwave infrared*, LWIR): $8.0\text{--}14.0\mu\text{m}$

Rozpoznawanie twarzy – analiza wielospektralna

- Obrazowanie w dalekiej podczerwieni
 - Analiza promieniowania generowanego (nie - odbitego) przez obiekt
 - Niezależność od oświetlenia
 - Poprawne działanie również w całkowitej ciemności
 - Zależność od temperatury otoczenia, warunków atmosferycznych, wiatru, etc.
 - Zależność od chwilowej intensywności procesów metabolicznych (wysiłek fizyczny, infekcje)
 - Okluzje spowodowane przez okulary

Jednoczesne wykorzystanie metod obrazowania w różnych zakresach długości fali pozwala na połączenie ich zalet i poprawę wyników w stosunku do pojedynczego zakresu (np. widzialnego)

Dziękuję za uwagę